

中国土地市场网爬取



安替
学生

10 人赞同了该文章 >

实习期间老板需要对土地数据进行爬取，想来想去就 Google 到了[中国土地网]([网站防火墙](#)). 应该算是种类最齐全的土地数据了。

Github 地址:

AnTi-anti/china_land
github.com/AnTi-anti/china_land/tree/master

目标分析⁺

https://img-blog.csdnimg.cn/20200613180233889.png#pic_center
img-blog.csdnimg.cn/20200613180233889.png#pic_center

需要提取的信息就是上方最终表格的信息。不同于上一篇



爬取徐州市自然资源和规划局土地数据_猫数里
博客
blog.csdn.net/weixin_35770067/article/details/11

这次爬取会涉及到几个难点。

网页结构⁺分析

我们首先进入官网，依次点击土地供应，结果公告。

https://img-blog.csdnimg.cn/20200613180458836.png#pic_center
img-blog.csdnimg.cn/20200613180458836.png#pic_center

就进入了接下来这个页面。

https://img-blog.csdnimg.cn/20200613180602789.png#pic_center
img-blog.csdnimg.cn/20200613180602789.png#pic_center

因为我们需要的是 2015-2020 年的数据。而且是根据行政区来依次进行爬取。所以，肯定需要用到 [selenium⁺](#) 进行爬取。和之前那一篇结构类似。也是先爬取土地坐落的链接，然后再爬取链接的详情页面。

第二种情况就是在云盘禁止访问JPG，一开始用的是免费的网盘，这个确实快，但是容量有限，所以爬取速度还不如没有代理的快些。后面就放弃了使用代理的想法。所以说遇到这种情况，只能暂时中止。但是在爬取链接页面的时候这种情况不会出现，而在对详情页进行提取的时候会出现。这时候我采取的措施是直接剔除掉已经爬取的链接，对剩余没有用到的链接继续提取详情页信息。

一开始我使用的是自己的宽带和局域网，经常会出现这种禁止访问的情况。但是后来我使用了华为的服务器竟然就没有这种情况。而且在同一时间段，我本机和与云服务器⁺同时在跑，本地就禁止，而云服务器依旧运行，很奇怪，如果有懂硬件的朋友了解的话，可以评论区告诉我，我也不知道自己猜的对不对。

https://img-blog.csdnimg.cn/20200613180819527.png#pic_center

第二种情况就是会在爬取的过程中频繁出现验证码的步骤。这个也不难，我们可以直接对其进行识别。如果出现验证码，则对其进行识别；否则，继续进行爬取。

```
def img_down_load(img):
    host = 'https://aip.baidubce.com/oauth/2.0/token?grant_type=client_credentials:'
    response = requests.get(host)
    request_url = "https://aip.baidubce.com/rest/2.0/ocr/v1/general_basic"
    # 二进制方式打开图片文件
    img = img.split(",")
    params = {"image": img[1]}
    access_token = response.json()['access_token']
    request_url = request_url + "?access_token=" + access_token
    headers = {"User-Agent": "Mozilla/5.0 (compatible; MSIE 9.0; Windows NT 6.1 Tr"}
    # headers = {'content-type': 'application/x-www-form-urlencoded'}
    response = requests.post(request_url, data=params, headers=headers)
    if response:
        counts = response.json()['words_result'][0]['words']
        return counts
```

第三种就是只显示前200页的数据。如果你是翻页进行爬取的话，那么只有200页的数据可以获取到，这时候我们就需要对时间进行筛选，在上述筛选框输入时间即可，再启动翻页设置。

https://img-blog.csdnimg.cn/20200613181809412.png#pic_center

第四种就是行政区域的设置。我们通过对源代码⁺进行分析，发现可以通过输入城市的身份证前4位进行判别。

https://img-blog.csdnimg.cn/20200613182015721.png#pic_center

关于作者



安替
学生

回答

0

文章

5

关注者

10

关注他

发私信

大家都在搜

换一换

- 豆包疑误导老人断指泡盐... 456万 热
- 王楚钦任国乒男队队长 410万 热
- 司马懿饰演者魏宗万去世 404万 热
- 高考朋友圈文案 373万
- 宁夏事业编考生因围报被... 341万 热
- 宝妈称带孩子去山姆是托... 331万 热
- 官方通报女大学生被騙入... 315万 热
- 如何让考试超常发挥的玄学 312万
- 苹果液态金属铰链折叠屏 309万
- AI脸引发网友生理性厌恶 295万 热

周报总结难写? 用豆包AI

一句话生成文档 条理清晰

豆包豆包，这是我的一周工作小结，帮我总结成一个周报文档。

豆包：好的，请提供您的工作小结内容，我将为您生成一份结构清晰的周报文档。

```
import requests
def img_down_load(img):
    host = 'https://aip.baidubce.com/oauth/2.0/token?grant_type=client_credential:'
    response = requests.get(host)
    request_url = "https://aip.baidubce.com/rest/2.0/ocr/v1/general_basic"
    # 二进制方式打开图片文件
    img = img.split(",")
    params = {"image": img[1]}
    access_token = response.json()['access_token']
    request_url = request_url + "?access_token=" + access_token
    headers = {"User-Agent": "Mozilla/5.0 (compatible; MSIE 9.0; Windows NT 6.1 Tr
    # headers = {'content-type': 'application/x-www-form-urlencoded'}
    response = requests.post(request_url, data=params, headers=headers)
    if response:
        counts = response.json()['words_result'][0]["words"]
        return counts
```

```
import time,json,random
from test import img_down_load
from selenium import webdriver
opt = webdriver.ChromeOptions()
headers = {"User-Agent": "Mozilla/5.0 (compatible; MSIE 9.0; Windows NT 6.1 Tridei
opt.add_argument('--user-agent=%s' % headers)
#opt.add_argument("--proxy-server=http://202.20.16.82:10152")
driver = webdriver.Chrome(options=opt)
driver.get("网站防火墙")
time.sleep(random.randint(2,5))
while True:
    if driver.find_element_by_xpath("/html/body/div/div[2]/table/tbody/tr[2]/td/i
        img = driver.find_element_by_xpath("/html/body/div/div[2]/table/tbody/tr[
        a = img_down_load(img)
        driver.find_element_by_xpath("//*[@id='intext']").send_keys(a)
        driver.find_element_by_xpath("/html/body/div/div[2]/table/tbody/tr[2]/td/
        time.sleep(random.randint(2,5))
    try:
        driver.find_element_by_id("TAB_QueryConditionItem256").click()
        driver.execute_script("document.getElementById('TAB_queryTblEnumItem_256_
        driver.find_element_by_id('TAB_queryTblEnumItem_256_v').clear()
        driver.find_element_by_id("TAB_queryTblEnumItem_256_v").send_keys('3203')
        driver.find_element_by_id("TAB_QueryButtonControl").click()
        break
    except:
        driver.refresh()
        continue
list_info = []

time.sleep(random.randint*(2,5))
try:
    if driver.find_element_by_xpath("/html/body/div/div[2]/table/tbody/tr[2]/td/i
        img = driver.find_element_by_xpath("/html/body/div/div[2]/table/tbody/tr[
        a = img_down_load(img)
        driver.find_element_by_xpath("//*[@id='intext']").send_keys(a)
        driver.find_element_by_xpath("/html/body/div/div[2]/table/tbody/tr[2]/td/
        driver.find_element_by_id("TAB_QueryConditionItem256").click()
        driver.execute_script("document.getElementById('TAB_queryTblEnumItem_256_
        driver.find_element_by_id('TAB_queryTblEnum
        driver.find_element_by_id("TAB_queryTblEnum
```

```
pass
```

```
num = 183
for pages in range(1,num):
    for i in range(2,32):
        try:
            if driver.find_element_by_xpath("/html/body/div/div[2]/table/tbody/tr
                img = driver.find_element_by_xpath("/html/body/div/div[2]/table/tl
                a = img_down_load(img)
                driver.find_element_by_xpath("//*[@id='intext']").send_keys(a)
                driver.find_element_by_xpath("/html/body/div/div[2]/table/tbody/tl
        except:
            pass

        try:
            urls = driver.find_element_by_xpath("//*[@id='TAB_contentTable']/tbody
        except:
            driver.refresh()
            num += 1
            continue
        print(urls)
        list_info.append(urls)
    try:
        driver.find_element_by_xpath+("//*[@id='mainModuleContainer_485_1113_1539
    except:
        pass
    time.sleep(random.randint(2,5))
    with open("徐州.json", "w", encoding="utf8") as f:
        json.dump(list_info,f,indent=1)

driver.quit()
```

我们将爬取到的链接保存在json文件里

```
https://img-
blog.csdnimg.cn/20200613182252325.png#pic_c...
img-blog.csdnimg.cn/20200613182252325.png#pic_center
```

第二步就是对链接进行详情页提取。

```
import time,json,random
from test import img_down_load
from selenium import webdriver

with open("徐州.json", "r", encoding="utf8") as f:
    urls = json.load(f)
opt = webdriver.ChromeOptions()
headers = {"User-Agent": "Mozilla/5.0 (compatible; MSIE 9.0; Windows NT 6.1 Trident
opt.add_argument('--user-agent=%s' % headers)
driver = webdriver.Chrome(options=opt)
for url in urls:
    print(url)
    driver.get(url)
    time.sleep(random.randint(2,5))
    tуди_dict = {}
    tуди_list = []
    while True:
```

```
a = img_down_load(img)
driver.find_element_by_xpath("//*[@id='intext']").send_keys(a)
driver.find_element_by_xpath("/html/body/div/div[2]/table/tbody/tr[2]/td[5]").send_keys(a)
time.sleep(random.randint(2,5))
except:
    print("没有验证码")

print("开始查找")
try:
    xingzhengqu_key = driver.find_element_by_xpath(
        "//*[@id='mainModuleContainer_1855_1856_ctl00_ctl00_p1_f1_r1_c1_ctl00']")
    try:
        xingzhengqu_value = driver.find_element_by_xpath(
            "//*[@id='mainModuleContainer_1855_1856_ctl00_ctl00_p1_f1_r1_ctl00']")
    except:
        xingzhengqu_value = ""
    print(xingzhengqu_key, xingzhengqu_value)

    xiangmu_name_key = driver.find_element_by_xpath(
        "//*[@id='mainModuleContainer_1855_1856_ctl00_ctl00_p1_f1_r17_c1_ctl00']")
    try:
        xiangmu_name_value = driver.find_element_by_xpath(
            "//*[@id='mainModuleContainer_1855_1856_ctl00_ctl00_p1_f1_r17_ctl00']")
    except:
        xiangmu_name_value = ""
    print(xiangmu_name_key, xiangmu_name_value)

    xiangmu_weizhi_key = driver.find_element_by_xpath(
        "//*[@id='mainModuleContainer_1855_1856_ctl00_ctl00_p1_f1_r16_c1_ctl00']")
    try:
        xiangmu_weizhi_value = driver.find_element_by_xpath(
            "//*[@id='mainModuleContainer_1855_1856_ctl00_ctl00_p1_f1_r16_ctl00']")
    except:
        xiangmu_weizhi_value = ""
    print(xiangmu_weizhi_key, xiangmu_weizhi_value)

    mianji_key = driver.find_element_by_xpath(
        "//*[@id='mainModuleContainer_1855_1856_ctl00_ctl00_p1_f1_r2_c1_ctl00']")
    try:
        mianji_value = driver.find_element_by_xpath(
            "//*[@id='mainModuleContainer_1855_1856_ctl00_ctl00_p1_f1_r2_ctl00']")
    except:
        mianji_value = ""
    print(mianji_key, mianji_value)

    yongtu_key = driver.find_element_by_xpath(
        "//*[@id='mainModuleContainer_1855_1856_ctl00_ctl00_p1_f1_r3_c1_ctl00']")
    try:
        yongtu_value = driver.find_element_by_xpath(
            "//*[@id='mainModuleContainer_1855_1856_ctl00_ctl00_p1_f1_r3_ctl00']")
    except:
        yongtu_value = ""
    print(yongtu_key, yongtu_value)

    fangshi_key = driver.find_element_by_xpath(
        "//*[@id='mainModuleContainer_1855_1856_ctl00_ctl00_p1_f1_r3_c3_ctl00']")
    try:
        fangshi_value = driver.find_element_by_xpath(
            "//*[@id='mainModuleContainer_1855_1856_ctl00_ctl00_p1_f1_r3_ctl00']")
    except:
        fangshi_value = ""
```

```
        "//*[@id='mainModuleContainer_1855_1856_ctl00_ctl00_p1_f1_r19_c1_0']"
    try:
        years_value = driver.find_element_by_xpath(
            "//*[@id='mainModuleContainer_1855_1856_ctl00_ctl00_p1_f1_r19_c1_0']"
        )
    except:
        years_value = ""
    print(years_key, years_value)

    hangye_type_key = driver.find_element_by_xpath(
        "//*[@id='mainModuleContainer_1855_1856_ctl00_ctl00_p1_f1_r19_c3_0']"
    )
    try:
        hangye_type_value = driver.find_element_by_xpath(
            "//*[@id='mainModuleContainer_1855_1856_ctl00_ctl00_p1_f1_r19_c3_0']"
        )
    except:
        hangye_type_value = ""
    print(hangye_type_key, hangye_type_value)

    pice_key = driver.find_element_by_xpath(
        "//*[@id='mainModuleContainer_1855_1856_ctl00_ctl00_p1_f1_r20_c3_0']"
    )
    try:
        pice_value = driver.find_element_by_xpath(
            "//*[@id='mainModuleContainer_1855_1856_ctl00_ctl00_p1_f1_r20_c3_0']"
        )
    except:
        pice_value = ""
    print(pice_key, pice_value)

    shiyong_key = driver.find_element_by_xpath(
        "//*[@id='mainModuleContainer_1855_1856_ctl00_ctl00_p1_f1_r9_c1_0']"
    )
    try:
        shiyong_value_1 = driver.find_element_by_xpath(
            "//*[@id='mainModuleContainer_1855_1856_ctl00_ctl00_p1_f1_r9_c1_0']"
        )
    except:
        shiyong_value_1 = ""

    try:
        shiyong_value_2 = driver.find_element_by_xpath(
            "//*[@id='mainModuleContainer_1855_1856_ctl00_ctl00_p1_f1_r23_c1_0']"
        )
    except:
        shiyong_value_2 = ""

    print(shiyong_key, shiyong_value_1+shiyong_value_2)

    rongjilv_key = driver.find_element_by_xpath(
        "//*[@id='mainModuleContainer_1855_1856_ctl00_ctl00_p1_f1_r21_c1_0']"
    )
    try:
        rongjilv_next_value = driver.find_element_by_xpath(
            "//*[@id='mainModuleContainer_1855_1856_ctl00_ctl00_p1_f2_r1_c1_0']"
        )
    except:
        rongjilv_next_value = ""

    try:
        rongjilv_up_value = driver.find_element_by_xpath(
            "//*[@id='mainModuleContainer_1855_1856_ctl00_ctl00_p1_f2_r1_c1_0']"
        )
    except:
        rongjilv_up_value = ""
    print(rongjilv_key, rongjilv_next_value, rongjilv_up_value)

    riqi_key = driver.find_element_by_xpath(
        "//*[@id='mainModuleContainer_1855_1856_ctl00_ctl00_p1_f1_r14_c3_0']"
    )
    try:
        riqi_value = driver.find_element_by
```

AnTi-anti/china_land
github.com/AnTi-anti/china_land/tree/master

发布于 2020-06-13 19:03

数据抓取 爬虫 (计算机网络) 网页爬虫

升级泽锐防蓝光后实际佩戴感受如何？

以前戴蔡司佳锐，这次买了自由环面泽锐，视野范围扩展了，防蓝光只挡有害蓝光、保留有益光，色差小，久看眼胀减轻，体验提升明显 [查看详情](#)

蔡司 的广告



未登录用户

2 条评论

默认 最新



牛奶味宝宝

楼主，出数据吗

2021-11-02

回复 喜欢



只要心够决


我这句 "from test import img_down_load" 总出错: ImportError: cannot import name 'img_down_load' from 'test' (E:\Program Files\Python\lib\test__init__.py), 是什么原因, 求教, 小白一枚



2020-07-04

回复 喜欢

推荐阅读



爬虫-如何采集住房列表下的详细信息？

月恒 发表于互联网数据...

其他系列一：一个数据分析人的网址书签

工作久了，会慢慢积累自己的网站，或工作或生活，作为数据分析，你会接触到很多网站，特别电商，有些公司涉及很多平台、erp等，对于人，需要整理自己的网站结构，其中经过多次改革替换 平...

星之幻境



爬取企查查--批发业企业的信息

年轻的战场 发表于数据分析

如何用隧道代理爬海外网站？

随着业务的逐步发展，越来越与世界接轨，很多公司，包括个人都需要爬取海外网站的一些数据，国内无法直接爬取，这成了很多人的难题。下面我这边介绍大家如何爬数据：： 首先我们租一台海外...

孤风